数据库构建

文档以Python举例，其他语言的思路应该是一致的，可能方法上略有不同：

主要流程大概是：数据库初始化 --> 提取器执行（通过AST生成trap文件） -- trap文件导入原始数据集 -- 生成最终database数据库

一、创建数据库

创建命令：

```
codeql database create codeql_security_test2 --language=python --source-root=D:/qy/codeql/codeql_learn
```

二、数据库目录结构

CodeQL database

A database (or CodeQL database) is a directory containing:

- queryable data, extracted from the code.
- a source reference, for displaying query results directly in the code.
- query results.
- log files generated during database creation, query execution, and other operations.

- db-python：可查询数据集
- log：创建和查询日志
- results：查询结果的bqrs文件，用来转换为其他结果格式
- src.zip：源代码

三、数据库生成原理

1、分析数据库构建日志

实际创建一个数据库，查看日志，大致分为一下三个阶段：

- 数据库初始化：

  创建空的codeql数据库

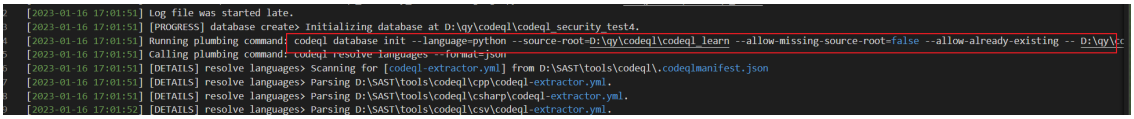

- 提取器执行：

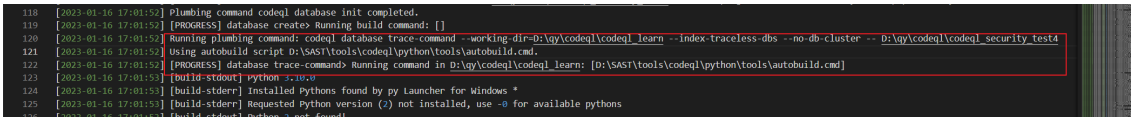

从上图可以看到提取器执行trace-command命令，以及自动构建脚本autobuild.cmd，主要为提取源码，基于AST生成trap文件，下面几小节分析。

- 数据集导入：

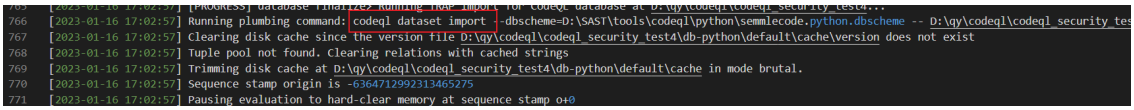

将tarp文件导入最终数据集，也就是 db-python 目录

2、自动构建脚本

```
@echo off

rem Legacy environment variables for the autobuild infrastructure.
set LGTM_SRC=%CD%
set LGTM_WORKSPACE=%CODEQL_EXTRACTOR_PYTHON_SCRATCH_DIR%

type NUL && python "%CODEQL_EXTRACTOR_PYTHON_ROOT%\tools\index.py"
exit /b %ERRORLEVEL%

```

- 执行当前目录的index脚本
- index脚本调用

```
import buildtools.index
buildtools.index.main()
```

- 解压python3src.zip 得到包：buildtools
- 接下来可自行构建相关Pycharm调试环境，这一步不赘述
- 有一些环境变量需自行添加
- 进行调试会发现主要入口调用：`python_tracer.py`，相关参数自行调试获取
-

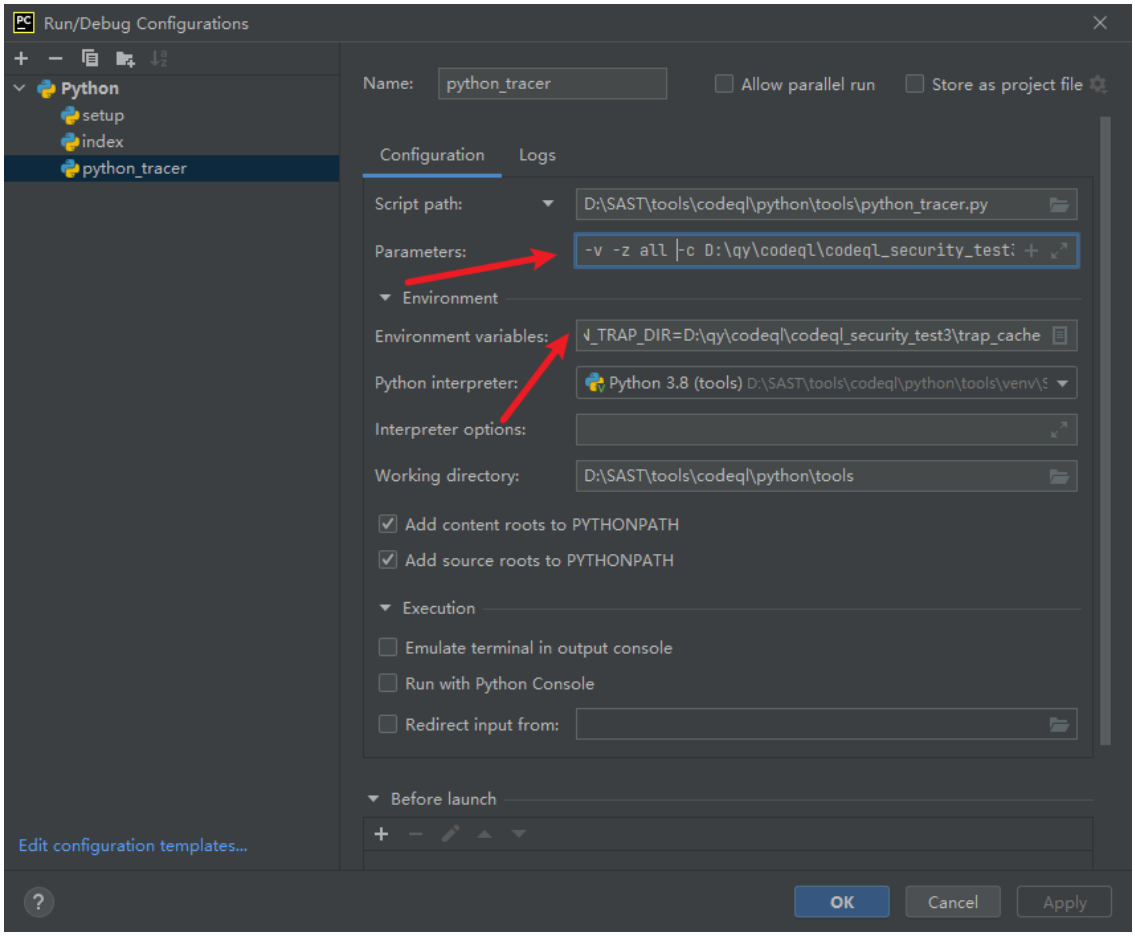

3、Python tracer

- 主要流程是：创建进程池+任务队列

```
class ExtractorPool(object):

    def __init__(self, outdir, archive, proc_count, options, logger):
        if (proc_count < 1):
            raise ValueError('Number of processes must be at least one.')
        self.verbose = options.verbose
        self.outdir = outdir
        self.max_import_depth = options.max_import_depth
        method = ('spawn' if (sys.platform == 'darwin') else None)
        try:
            ctx = mp.get_context(method)
        except AttributeError:
            ctx = mp
        self.module_queue = ctx.Queue((proc_count * 2))
        self.reply_queue = ctx.Queue((proc_count * 20))
        self.archive = archive
        self.local_queue = deque()
        self.enqueued = set()
        self.done = set()
        self.requirements = {}
        self.import_graph = ModuleImportGraph(options.max_import_depth)
        logger.debug('Source archive: %s', archive)
        self.logger = logger
        args = (self.module_queue, outdir, archive, options, self.reply_queue, logger)
        self.procs = [ctx.Process(target=_extract_loop, args=((((n + 1),) + args) + ((n == 0),))) for n in range(proc_count)]
        for p in self.procs:
            p.start()
        self.start_time = time.time()
```

- 进程池调用提取器函数处理文件
- 遍历所有文件，逐个文件发给上述队列处理

4、提取器

做扫描引擎开发的可能感兴趣这一块

- 分为内建提取器、第三方包提取器、代码提取器、包提取器、文件提取器

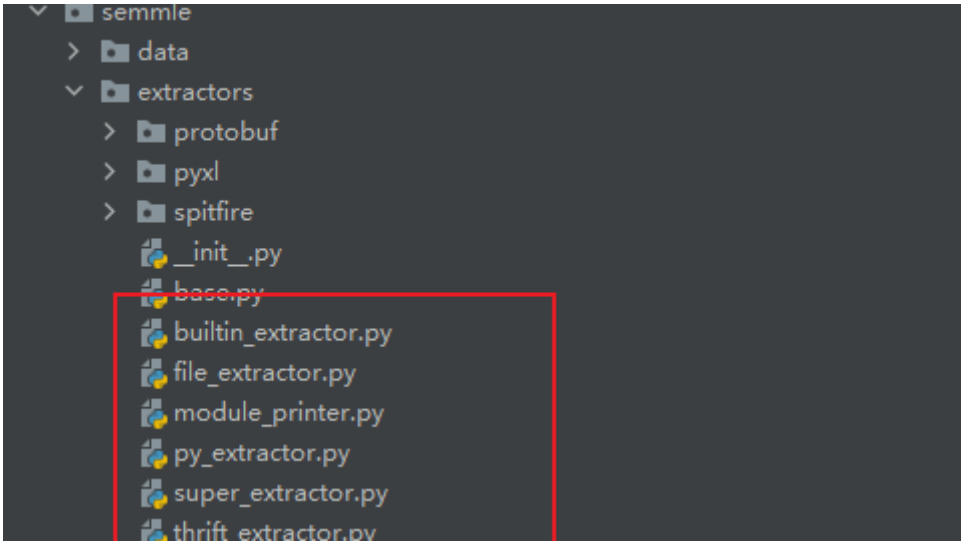

- 遍历、递归处理每一个文件，以及文件import 的包，递归将每一个包以及依赖的系统包和第三方包全部处理，都会从系统安全的Python环境里查找

```
219                 start = time.time()   start: 1674985939.2660053
220                 imports = extractor.process(unit)   imports:
221                 end_time = time.time()
222                 extraction_time += (end_time - start)
223                 if (imports is SkippedBuiltin):
224                     logger.info('Skipped built-in %s', unit)
225                 else:
226                     for imp in imports:
227                         reply_queue.put(('IMPORT', unit, imp))
228                     send_time += (time.time() - end_time)
229                     logger.info('Extracted %s in %0.0fms', unit, ((end_time - start) * 1000))
```

- 源码处理模块：主要处理入口`process_source_module`

```
211     def process_source_module(self, module):
212         if (self.worker is None):
213             raise Exception('worker is not set')
214         key = self.get_cache_key(module)
215         trap = self.cache.get(key)
216         if (trap is None):
217             trap = self.worker.process_source_module(module)
218             if (trap is not None):
219                 self.cache.set(key, trap)
220         else:
221             self.logger.debug('Found cached trap file for %s', module.path)
222             self.worker.trap_folder.write_trap('python', module.path, trap)
223             try:
224                 self.worker.copy_source(module.bytes_source, module.trap_name, module.path)
225             except Exception:
226                 self.logger.traceback(WARN)
227         return trap
```

- 三阶段pass处理AST，有点类似于LLVM pass阶段了
  - 处理AST的基本结构
  - 处理导出表
  - 处理函数调用，生成调用图

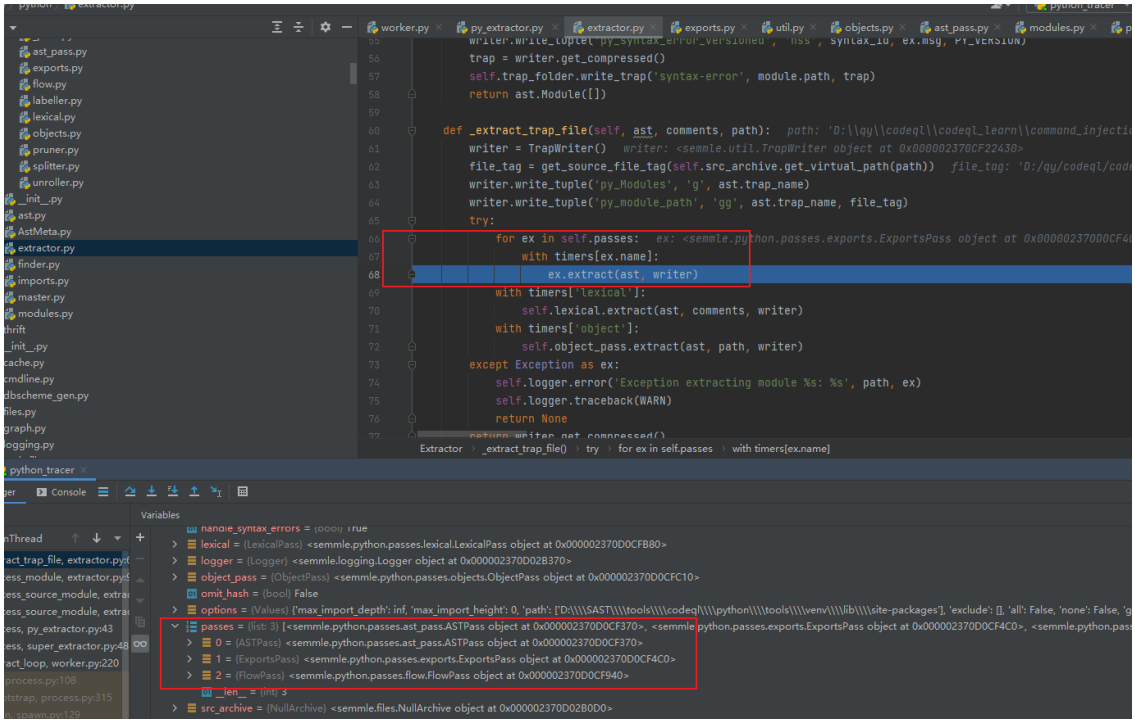

- 处理完成写入trap文件：压缩包

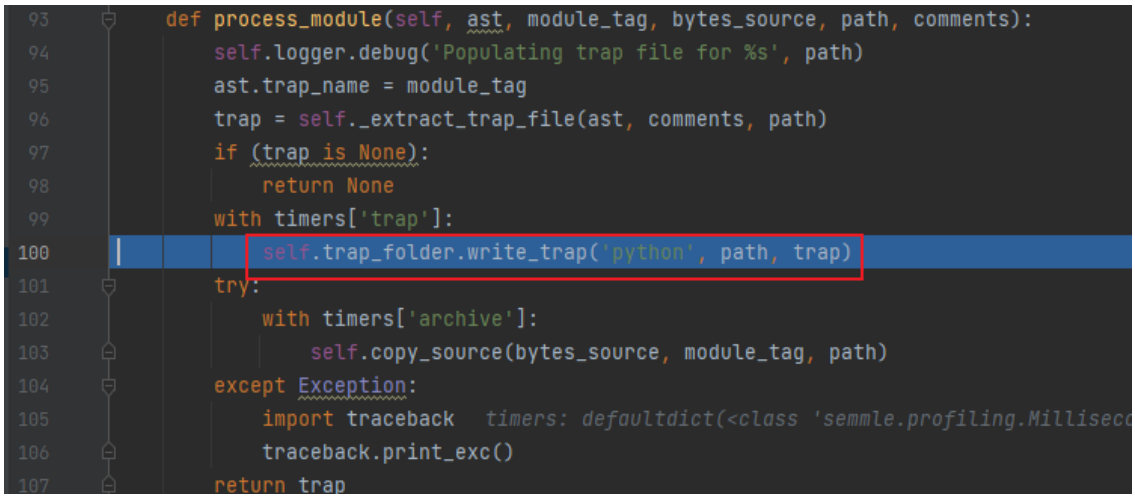

5、trap文件

- 解压trap文件查看

odeql > codeql_security_test3 > trap_cache > command_injection.py.p6B3zpPOPkVgeZ4qCpH-aNRjq8w=.trap

```
#10000 = @"PythonSourceModule:D:\qy\codeql\codeql_learn\command_injection.py:BvlaqzFr7kuu6bhqf8yn6Y4TkLw="
py_Modules(#10000)
#10001 = @"D:/qy/codeql/codeql_learn/command_injection.py;sourcefile"
py_module_path(#10000, #10001)
#10002 = *
#10003 = @"PythonSourceModule:D:\qy\codeql\codeql_learn\command_injection.py:BvlaqzFr7kuu6bhqf8yn6Y4TkLw="
variable(#10002, #10003, "__name__")
#10004 = *
variable(#10004, #10003, "__package__")
#10005 = *
variable(#10005, #10003, "$")
py_extracted_version(#10000, "3")
py_Modules(#10003)
#10006 = *
py_stmt_lists(#10006, #10003, 2)
#10007 = *
py_stmts(#10007, 12, #10006, 0)
py_scopes(#10007, #10003)
#10008 = *
py_alias_lists(#10008, #10007)
#10009 = *
py_aliases(#10009, #10008, 0)
#10010 = *
py_exprs(#10010, 13, #10009, 0)
py_scopes(#10010, #10003)
py_ints(0, #10010)
py_strs("subprocess", #10010, 3)
py_bools(#10010, 4)
#10011 = *
py_exprs(#10011, 19, #10009, 1)
py_scopes(#10011, #10003)
#10012 = *
variable(#10012, #10003, "subprocess")
py_variables(#10012, #10011)
#10013 = *
py_expr_contexts(#10013, 5, #10011)
#10014 = *
py_stmts(#10014, 12, #10006, 1)
py_scopes(#10014, #10003)
#10015 = *
py_alias_lists(#10015, #10014)
#10016 = *
py_aliases(#10016, #10015, 0)
#10017 = *
py_exprs(#10017, 13, #10016, 0)
py_scopes(#10017, #10003)
py_ints(0, #10017)
```

- tarp文件格式：datalog数据查询语言

> Datalog是一种数据查询语言，专门设计与大型关系数据库交互[1]，语法与Prolog相似。正如SQL只是一个规范，Transact-SQL、PL-SQL是其具体实现一样；Datalog也是一个规范，bddbddb[2]、DES[3]、OverLog[4]、Deals[5]等都按照Datalog的语法实现了自己的语言，所以Datalog没有特定的执行环境（如Java之于Java虚拟机，Prolog之于SWI-Prolog）。

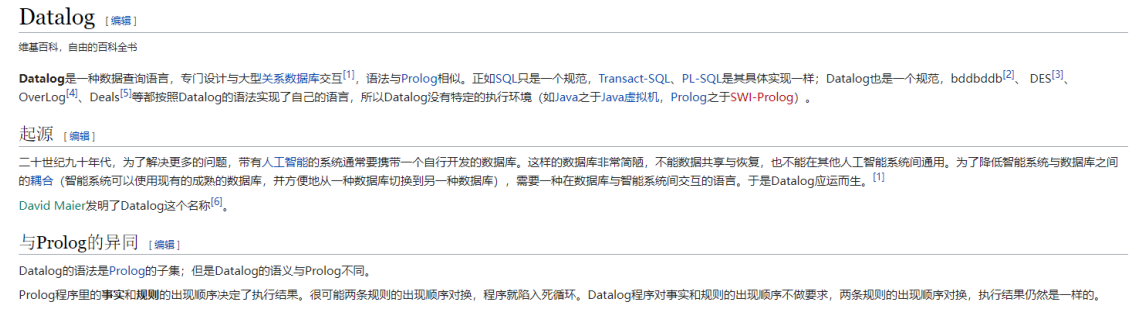

Datalog [编辑]

维基百科，自由的百科全书

Datalog是一种数据查询语言，专门设计与大型关系数据库交互[1]，语法与Prolog相似。正如SQL只是一个规范，Transact-SQL、PL-SQL是其具体实现一样；Datalog也是一个规范，bddbddb[2]、DES[3]、OverLog[4]、Deals[5]等都按照Datalog的语法实现了自己的语言，所以Datalog没有特定的执行环境（如Java之于Java虚拟机，Prolog之于SWI-Prolog）。

起源 [编辑]

二十世纪九十年代，为了解决更多的问题，带有人工智能的系统通常要携带一个自行开发的数据库。这样的数据库非常简陋，不能数据共享与恢复，也不能在其他人工智能系统间通用。为了降低智能系统与数据库之间的耦合（智能系统可以使用现有的成熟的数据库，并方便地从一种数据库切换到另一种数据库），需要一种在数据库与智能系统间交互的语言。于是Datalog应运而生。[1]

David Maier发明了Datalog这个名称[6]。

与Prolog的异同 [编辑]

Datalog的语法是Prolog的子集；但是Datalog的语义与Prolog不同。

Prolog程序里的**事实**和**规则**的出现顺序决定了执行结果。很可能两条规则的出现顺序对换，程序就陷入死循环。Datalog程序对事实和规则的出现顺序不做要求，两条规则的出现顺序对换，执行结果仍然是一样的。

6、rel文件

- 上述trap文件生成后，codeql命令行执行 数据集导入，生成最终rel二进制文件，用来最终进行查询
- rel文件是自动生成，可以不用关注
- 生成rel文件后，数据库最终生成